

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Ciencias de la Computación

Deep Learning - Semestre II 2026



Proyecto #1

Integrantes del grupo

Nina Najera #231088

José Antón #221041

Guatemala, 2 de septiembre de 2026

1. Resumen

Este trabajo evalúa si el orden de las transacciones aporta información que no aparece en las variables agregadas. Se comparó un modelo de Gradient Boosting con una LSTM que procesa eventos ordenados. Ambos modelos utilizan las mismas muestras, la misma partición temporal y el mismo horizonte de predicción.

El Modelo B obtuvo un AUC-PR de 0.9768 y el Modelo A obtuvo 0.9696. La diferencia global es pequeña. B detectó una mayor proporción de fraudes y redujo el costo de Q54,120 a Q44,160 en el período de prueba. A mantuvo mejor precisión y F1. La recomendación es probar B en paralelo al sistema actual y no reemplazar A de inmediato.

Repositorio: <https://github.com/Anton17303/Deep-Learning>

2. Integridad de datos y protocolo temporal

Se utilizó un generador sintético con semilla fija 20260905. Se produjeron 102,087 transacciones de 700 clientes durante 120 días. La tasa de fraude fue 1.14 %. El notebook verifica que dos ejecuciones con la misma semilla producen exactamente los mismos datos.

Se simularon tres mecanismos de fraude. Escalada contiene varias compras pequeñas seguidas por una compra grande. Ráfaga contiene varias compras pequeñas en distintos comercios y en pocos minutos. Canal raro representa una compra grande en un horario y una categoría poco habituales.

Cada muestra contiene siete transacciones históricas y la transacción actual. El Modelo A recibe ocho variables agregadas causales. El Modelo B recibe monto, categoría, canal, hora y tiempo desde el evento anterior.

Partición	Muestras	Uso
Entrenamiento	58,313	Ajuste de los modelos y parámetros de preparación
Validación	19,437	Selección de umbrales y evaluación de la apuesta C
Prueba	19,437	Fase final de evaluación

Cuadro 1: Partición temporal del conjunto de datos

La división respeta el tiempo. Los datos antiguos se usan para entrenamiento y las fechas finales se reservan para prueba. Los escaladores y las estadísticas de normalización se calculan solamente con entrenamiento. Las decisiones y los umbrales se cierran antes de abrir prueba.

3. Comparación de los modelos A y B

El Modelo A utiliza Gradient Boosting sobre variables agregadas. El Modelo B utiliza una LSTM de una capa sobre ocho eventos ordenados. Los dos modelos producen un puntaje continuo de riesgo. AUC-PR es la métrica principal porque el conjunto está desbalanceado.

Modelo	AUC-PR val	AUC-PR test	Umbral	Precisión	Exhaustividad	F1
A - agregado	0.9477	0.9696	0.04	84.0 %	95.5 %	0.894
B - secuencial	0.9571	0.9768	0.60	61.0 %	98.3 %	0.753

Cuadro 2: Comparación común entre A y B




Figura 1: Curvas de precisión y exhaustividad de los modelos A y B

B mejoró AUC-PR en 0.0072. También redujo los falsos negativos y el costo. A generó menos falsos positivos y obtuvo mejor precisión y F1. Estos resultados muestran que la decisión debe considerar las consecuencias operativas y no solamente el AUC-PR.

4. Valor del orden

4.1. Permutación controlada

La prueba mantiene fija la transacción actual y baraja únicamente las siete transacciones históricas. De esta forma se destruye el orden del historial sin cambiar el evento que se desea clasificar.




Figura 2: Resultado de la permutación controlada del historial

El AUC-PR de B bajó de 0.9768 a 0.9468. La caída absoluta fue 0.0301. El resultado indica que el orden histórico aporta información, pero su efecto es moderado.

4.2. Desempeño por mecanismo




Figura 3: Desempeño de A y B por mecanismo de fraude

Mecanismo	Casos	AUC-PR A	AUC-PR B	Ventaja B
Escalada	23	0.967	0.717	-0.250
Ráfaga	207	0.962	0.977	0.015
Canal raro	12	0.988	0.476	-0.512

Cuadro 3: Resultados separados por mecanismo de fraude

La ventaja de B se concentró en ráfaga. B quedó por debajo de A en escalada y canal raro. Por esta razón no se afirma que el orden sea útil en todos los mecanismos. Las muestras de escalada y canal raro también son pequeñas y producen estimaciones menos estables.

5. Apuesta del equipo

La hipótesis previa estableció que combinar los puntajes de A y B mejoraría AUC-PR porque ambos modelos capturan señales diferentes. El control fue el mejor modelo individual dentro de cada partición. La apuesta se consideró útil si el margen medio era al menos 0.01.

Medida	Resultado
AUC-PR medio del híbrido	0.9748
AUC-PR medio del control	0.9612
Margen medio	0.0136
Regla de éxito	0.0100
AUC-PR de C en prueba	0.9847

Cuadro 4: Evaluación de la apuesta C

El margen medio superó la regla previa. La apuesta se considera útil. C alcanzó el mayor AUC-PR final, pero requiere ejecutar los dos modelos base. Se conserva como una extensión para el Proyecto Final.

6. Decisión económica

El costo de un fraude no detectado es Q4,200. El costo de bloquear una transacción legítima es Q180. Los umbrales se seleccionaron con validación y se aplicaron sin ajustes en prueba.

Escenario	Umbral	FN	FP	Precisión	Exhaustividad	F1	Costo
Sin modelo	-	242	0	-	0.0 %	-	Q1,016,400
Modelo A	0.04	11	44	84.0 %	95.5 %	0.894	Q54,120
Modelo B	0.60	4	152	61.0 %	98.3 %	0.753	Q44,160

Cuadro 5: Costo de los modelos en el conjunto de prueba




Figura 4: Costo de los escenarios evaluados

B ahorró Q9,960 frente a A durante 22.48 días. El ahorro normalizado a treinta días y al mismo tamaño de la simulación es Q13,293.

Una estimación simple para 1.4 millones de tarjetas y una tasa de fraude entre 0.1 % y 0.3 % produce un rango de Q2.3 a Q7.0 millones al mes. Este rango no es un pronóstico. Supone un escalamiento lineal y no descuenta infraestructura, revisión humana ni fricción con clientes.

7. Recomendación y límites

Se recomienda complementar el sistema actual con B durante un piloto en paralelo. B reduce los falsos negativos de 11 a 4 y obtiene el menor costo. A conserva mejor precisión y F1, por lo que todavía sirve como referencia y respaldo.

Los principales patrones de error aparecen en canal raro y escalada. En ambos casos A supera a B porque el monto actual contiene una señal fuerte. B es más útil en ráfaga, donde ninguna compra individual es extrema.

La recomendación cambiaría si los datos reales muestran pocos fraudes tipo ráfaga, si el costo operativo de B supera el ahorro o si los falsos positivos generan una carga de revisión inaceptable. C tendría prioridad si su ventaja se repite en datos reales y se define un umbral económico con una validación independiente.

Las principales limitaciones son los datos sintéticos, la tasa de fraude elevada, la ventana fija de ocho eventos y la cantidad reducida de casos en dos mecanismos. Antes de producción se necesitan datos reales, calibración de puntajes, costos operativos, variables de dispositivo y ubicación, seguimiento de deriva y una regla para clientes con poco historial.

8. Matriz de evidencias

Evidencia	Figura o tabla	Conclusión	Limitación
Integridad de datos	Tabla 1	Generador reproducible, ventanas causales y división temporal	Los datos no representan fraude real
Comparación común	Figura 1 y Tabla 2	B mejora AUC-PR y exhaustividad. A mejora precisión y F1	La diferencia de AUC-PR es pequeña
Permutación controlada	Figura 2	Alterar solo el historial reduce AUC-PR en 0.0301	La evidencia del orden es moderada
Prueba por mecanismo	Figura 3 y Tabla 3	La ventaja de B se concentra en ráfaga	Hay pocos casos de escalada y canal raro
Apuesta C	Tabla 4	El margen medio supera la regla previa	C requiere ejecutar los dos modelos base
Decisión económica	Figura 4 y Tabla 5	B ahorra Q9,960 frente a A	Los costos y el volumen son simulados
Recomendación y límites	Sección 7	Se propone un piloto de B junto al sistema actual	Falta validación real y medición operativa

La decisión final es realizar un piloto controlado de B junto al sistema actual. Durante el piloto se debe medir el ahorro neto, la carga de revisión, la calibración y el desempeño por mecanismo. C se conserva como candidato para una evaluación independiente en el Proyecto Final.