

Monitoreo transaccional: detectar lo que el orden revela

Informe para el Comité de Riesgos — Banco del Altiplano · Proyecto 1, Deep Learning 2026, UVG

Resumen ejecutivo

Evaluamos si el orden en que ocurren las transacciones de un cliente aporta información de riesgo que las variables agregadas actuales no capturan. Construimos un modelo de línea base sobre variables agregadas (Modelo A) y un modelo secuencial LSTM que lee las transacciones en su orden real (Modelo B), sobre datos sintéticos con tres mecanismos de fraude distintos. **El orden sí aporta señal medible**: al barajar el orden interno de las secuencias, el desempeño del Modelo B cae de forma pronunciada. Sin embargo, esa ventaja **no es uniforme**: se concentra en el mecanismo de fraude tipo ráfaga (varias transacciones pequeñas y rápidas), mientras que en fraudes que ya delatan un monto extremo el modelo agregado es suficiente. Con los costos declarados por el comité (Q4,200 por fraude no detectado, Q180 por bloqueo indebido), el Modelo B reduce el costo esperado frente al Modelo A en el conjunto de prueba. Recomendamos pilotear el modelo secuencial en paralelo al sistema actual, no reemplazarlo de inmediato.


1. Integridad de datos y protocolo

Usamos la **Ruta A (datos sintéticos con generador propio)**, con semilla fija (verificamos que el generador produce exactamente los mismos datos con la misma semilla). Simulamos 700 tarjetahabientes durante 120 días (~102,000 transacciones), cada uno con un perfil de gasto propio (monto típico, comercios y horario habituales). Inyectamos tres mecanismos de fraude: (1) *escalada* — varias compras pequeñas seguidas de una grande, en ese orden; depende principalmente de la secuencia. (2) *ráfaga* — muchas transacciones pequeñas en distintos comercios en pocos minutos (tarjeta clonada / card testing). (3) *canal_raro* — una transacción grande, fuera de horario y categoría habituales del cliente. La tasa de fraude resultante (~1.1%) es más alta que la tasa típica real (0.1%-0.3%) para tener suficientes casos de entrenamiento; esto se declara como limitación.

Para cada transacción con al menos 8 transacciones previas del mismo cliente construimos (a) 8 variables agregadas *causales* (monto promedio 24h, transacciones en la última hora, monto máximo del día, diversidad de comercios en 24h, monto actual, hora, minutos desde la transacción anterior, comercio nuevo) — esto es lo único que ve el Modelo A — y (b) la secuencia ordenada de esas 8 transacciones — lo único que ve el Modelo B. La partición train/validación/prueba es **estrictamente temporal** (60/20/20 por fecha, no aleatoria) y los escaladores/normalizaciones se ajustan solo con el conjunto de entrenamiento, evitando fuga de información del futuro o del conjunto de prueba.

2. Comparación común: A vs. B

El Modelo A es un *Gradient Boosting* sobre las variables agregadas. El Modelo B es un LSTM de una capa que procesa la secuencia ordenada de 8 eventos (monto, hora, categoría, canal, tiempo desde la transacción anterior) sin ver ningún agregado. Ambos producen un puntaje continuo de riesgo; la decisión de umbral se toma después (Sección 5). Usamos AUC-PR como métrica principal por tratarse de un problema fuertemente desbalanceado.




Modelo	AUC-PR (val)	AUC-PR (test)
A — agregado	0.943	0.945
B — secuencial (LSTM)	0.978	0.965

El Modelo B supera al Modelo A en AUC-PR de prueba (0.965 vs. 0.945): una mejora real pero moderada, no dramática, en el agregado de los tres mecanismos de fraude combinados.


3. Valor del orden: dos pruebas de falsificación

Prueba 1 — Permutación controlada. Barajamos el orden de los eventos dentro de cada secuencia de prueba, sin tocar los eventos ni los agregados, y reevaluamos el Modelo B (10 repeticiones).



El AUC-PR cae de 0.965 (orden real) a 0.343 en promedio (orden permutado) — una caída relativa de ~64%. Esto demuestra que el Modelo B **sí depende del orden interno**, no solo de qué transacciones aparecen en la ventana. Advertencia honesta: el LSTM pondera más el último evento de la secuencia (su estado oculto final); parte de la caída puede deberse a que la permutación saca el evento más informativo de la última posición, y no únicamente a que se pierda "la trayectoria" temporal en sí. La Prueba 2 ayuda a matizar esta lectura.

Prueba 2 (elegida por el equipo) — Desempeño por mecanismo de fraude. Medimos AUC-PR de A y B por separado para cada uno de los tres mecanismos sintéticos, para ver si la ventaja de B se concentra en el fraude diseñado para depender del orden (escalada) o es más general.



Resultado, honesto y algo contraintuitivo respecto al diseño original: el Modelo A ya detecta muy bien *escalada* (AUC-PR 0.996) y *canal_raro* (AUC-PR 0.691) porque ambos terminan en un monto extremo que una sola variable agregada (monto actual o máximo del día) ya delata — el orden ayuda poco ahí, y de hecho B rinde algo peor que A en esos dos casos. La ventaja de B se concentra en *ráfaga* (AUC-PR 0.962 vs. 0.948 de A), el mecanismo donde ninguna transacción individual es grande pero el patrón de frecuencia y sucesión sí lo es. Como la mayoría de los fraudes de prueba son de tipo ráfaga, esto también explica la caída grande de la Prueba 1. **Conclusión matizada:** el orden aporta información real, pero de forma específica al mecanismo de fraude, no de forma universal — no podemos afirmar que "el orden siempre ayuda", solo que ayuda cuando el monto de una

sola transacción no es ya suficientemente delator.


4. Apuesta del equipo (C): modelo híbrido A + B

Hipótesis declarada antes de tocar el conjunto de prueba: "Creemos que un modelo híbrido (stacking) que combine el score de A y el score de B mejorará el AUC-PR en validación, porque distintos mecanismos de fraude dejan huellas distintas — unos en el monto extremo (que A ya captura) y otros en el patrón temporal fino (que B captura mejor). Lo consideraremos útil si el AUC-PR promedio en 5-fold CV sobre validación supera al máximo de A y B individuales por un margen ≥ 0.01 . El control es usar solo el mejor modelo individual."

Resultado: el control (mejor individual en validación) fue 0.978; el híbrido en validación con validación cruzada de 5 particiones dio 0.982 ± 0.012 — un margen de solo +0.004, por debajo del umbral que nos comprometimos a exigir. **Veredicto: no concluyente**, según nuestro propio criterio pre-registrado. En la verificación única sobre el conjunto de prueba, el híbrido sí superó a B por un margen mayor (0.981 vs. 0.965), pero **no usamos esa observación para cambiar el veredicto** — el criterio de éxito se fijó antes de ver el test justamente para no reinterpretar la apuesta a la luz de un resultado favorable después de los hechos. Registramos esta observación como una pista prometedora para el Proyecto Final, no como una conclusión validada hoy.

5. Decisión económica

Con costo de Q4,200 por fraude no detectado y Q180 por bloqueo indebido, elegimos el umbral que minimiza el costo esperado **usando solo el conjunto de validación** (nunca el de prueba), y lo aplicamos una sola vez sobre el conjunto de prueba.



Escenario	Umbral	Falsos negativos	Falsos positivos	Precisión	Exhaustividad	Costo (test)
Sin modelo	—	259	0	—	0%	Q1,087,800
Modelo A	0.01	14	251	49.4%	94.6%	Q103,980
Modelo B	0.63	7	112	69.2%	97.3%	Q49,560

El Modelo B ahorra Q54,420 adicionales frente al Modelo A en el período de prueba simulado. Nuestra tasa de fraude sintética es más alta que la real, así que esta cifra en quetzales no debe leerse literalmente; escalando el volumen transaccional al tamaño de Banco del Altiplano (1.4M tarjetas) y ajustando a la baja por esa diferencia de tasa (factor conservador ~7-10x menor que una extrapolación directa), el ahorro mensual direccional de B sobre A se ubica en un rango de varios millones de quetzales al mes — suficiente para justificar operar un modelo secuencial en producción, incluso bajo supuestos conservadores.

6. Recomendación y límites

Recomendación: complementar, no reemplazar. El Modelo B mejora AUC-PR, reduce el costo esperado, y la Prueba 1 confirma que el orden aporta señal real y medible. Pero esa ventaja no es uniforme entre mecanismos de fraude (Prueba 2), y la apuesta de combinarlo con A (C) no alcanzó el umbral de éxito que nos comprometimos a exigir antes de ver el test. Proponemos pilotear B en paralelo al sistema actual — con foco en los casos tipo ráfaga, donde su ventaja es más clara — antes de decidir un reemplazo total.

Patrón de error concreto: en el conjunto de prueba, ambos modelos fallan más en *canal_raro* (AUC-PR más bajo de los tres mecanismos: 0.69 en A, 0.40 en B) — transacciones únicas, sin historial similar previo, donde 8 transacciones de contexto no bastan para establecer una línea base clara del comportamiento reciente del cliente.

Condiciones bajo las que cambiaría la recomendación: si al validar con datos reales la proporción de fraudes tipo ráfaga es baja frente a fraudes de monto extremo, la ventaja de B se diluiría y no justificaría el costo operativo adicional de mantener un modelo secuencial. Si la apuesta híbrida (C) alcanza el umbral de éxito con más datos de validación en el Proyecto Final, recomendaríamos adoptar C en lugar de B solo.

Limitaciones principales: datos sintéticos (no observamos fraude real ni su deriva en el tiempo); tasa de fraude inflada respecto a la real; muestras pequeñas para escalada (28 casos de prueba) y *canal_raro* (16 casos), lo que

hace ruidosas esas estimaciones; ventana fija de 8 eventos, que puede ser insuficiente para clientes de bajo uso de tarjeta.