Text-to-SQL con QLoRA

Generación de consultas MySQL a partir de preguntas en español

Qwen2.5-Coder-0.5B-Instruct

Nina Nájera · Alejandro Antón
Deep Learning · Universidad del Valle de Guatemala

Contrato de inferencia

Se recibe el esquema completo de la base y una pregunta en español. Se devuelve una sola consulta SELECT o WITH SELECT.

Generación: determinista, sin APIs externas para producir la consulta.

Límites: 300 segundos para cargar el modelo y 30 segundos por pregunta.

Motor: MySQL 8.4.10 con ONLY_FULL_GROUP_BY activo.

Fuente: solucion.py, config.json

Dataset y separación por esquema

Se aceptaron 3,023 pares de 3,102 candidatos. Se descartaron 75 consultas con resultado vacío y 4 con más de 500 filas.

Nivel	Entrenamiento	Validación
Fácil	1,086	12
Medio	891	14
Difícil	1,046	14

Entrenamiento: 10 dominios, con nombres completos y abreviados.
Validación: hotel y fútbol, sin presencia en entrenamiento.

Fuente: datos/reporte_datos.json, datos/validacion/preguntas.jsonl

Exactitud por ejecución

La comparación utiliza los resultados de ejecutar el SQL, en lugar de exigir el mismo texto que la referencia.

EX = suma de pesos acertados / suma de pesos
Fácil: 1 · Medio: 2 · Difícil: 3 · Peso total: 82

El orden cuenta cuando se solicita. Los números se redondean a dos decimales y se permiten columnas adicionales.

La prueba con las referencias alcanzó EX 1.000. Ese valor comprueba el evaluador y no representa al modelo.

Fuente: evaluador.py, resultados/oraculo.json

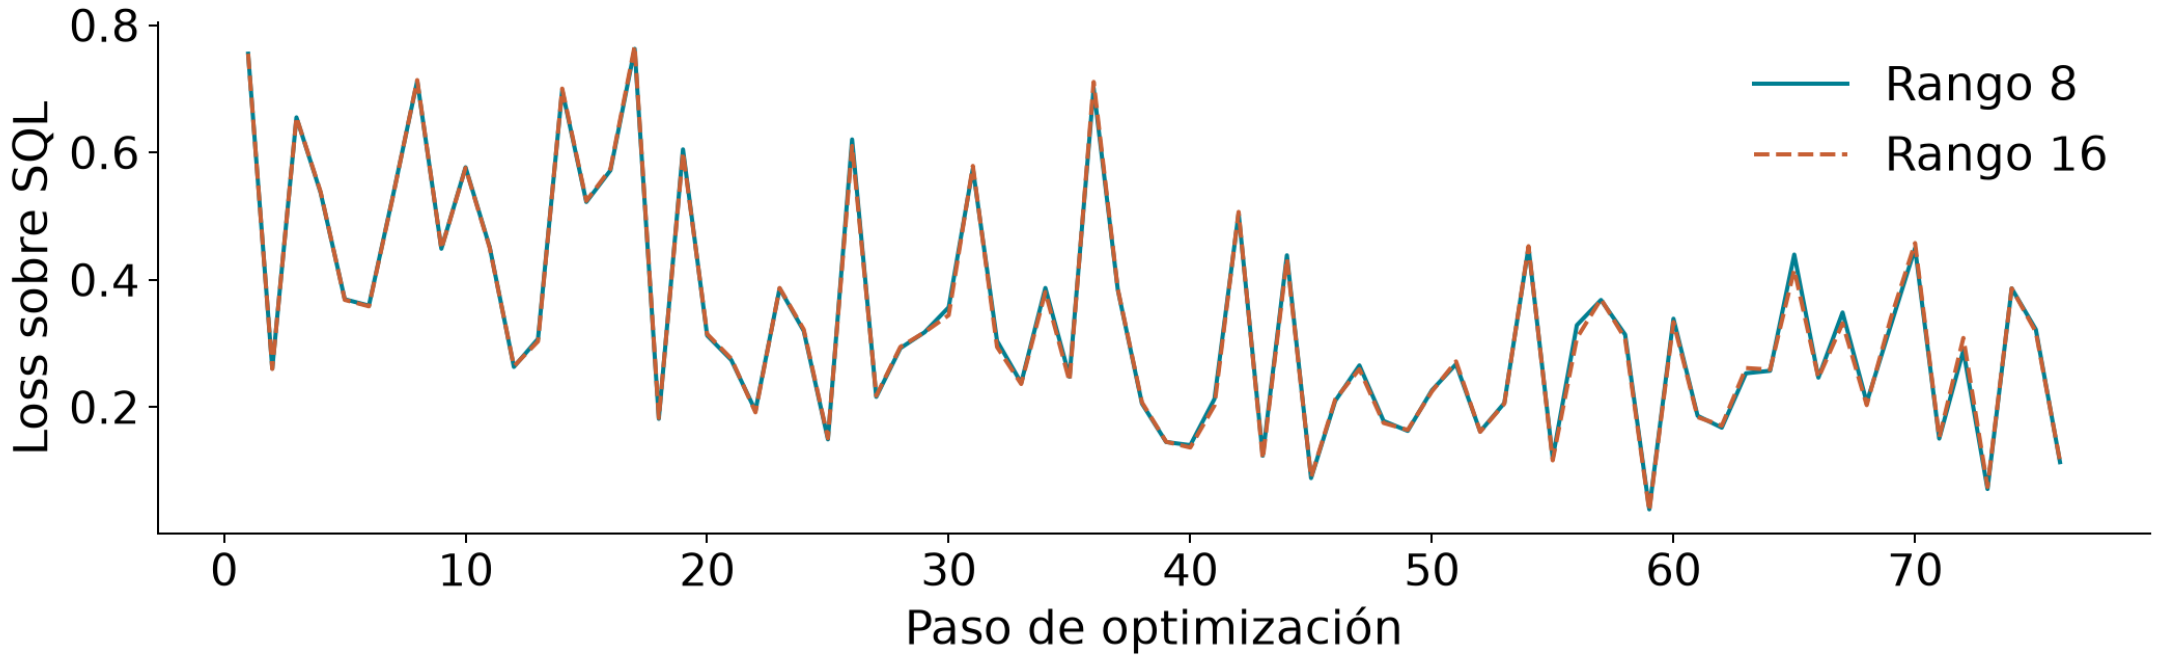
Comparación controlada de QLoRA

Factor	Rango 8	Rango 16
Parámetros entrenables	540,672	1,081,344
Pasos / ejemplos procesados	76 / 304	76 / 304
Tiempo de entrenamiento	37.1 min	41.0 min
Base y precisión	NF4 / FP16	NF4 / FP16

Hipótesis previa: el rango 16 puede representar más relaciones; el rango 8 puede reducir el sobreajuste. Se mantienen alpha 16, dropout 0.05, módulos q_proj/v_proj y tasa 0.0002.

Fuente: experimentos.md, resultados/lora_r8/resumen.json, resultados/lora_r16/resumen.json

Curvas de entrenamiento



La pérdida se calcula solo sobre la respuesta SQL. Los ejemplos cambian entre pasos, por lo que las curvas no tienen que ser monótonas.

Fuente: resultados/lora_r8/loss.csv, resultados/lora_r16/loss.csv

Resultados en validación propia

Configuración	Aciertos	EX	Máximo (s)
Base NF4	15/40	0.280	25.44
QLoRA rango 8	21/40	0.439	25.27
QLoRA rango 16	20/40	0.402	25.31
Adapter + reparación	21/40	0.427	27.22
Selección final	21/40	0.439	25.27

Se seleccionó rango 8. La reparación se mantuvo desactivada para la entrega.

Fuente: resultados/resumen_resultados.json

Experimento de reparación

Se mantiene el adapter seleccionado y se activa la corrección de identificadores y de errores de ejecución.

Inferencia	EX ponderada
Sin reparación	0.439
Con reparación	0.427

Se permiten dos ejecuciones de diagnóstico y un presupuesto conjunto de 25 segundos. Una consulta ejecutable puede seguir teniendo errores de significado.

Fuente: resultados/seleccion.json, resultados/reparacion.csv

Análisis de errores

Categoría	Cantidad
columna o tabla inexistente	8
agregación	5
filtro	3
JOIN	2
sintaxis	1

Se distingue entre fallos de ejecución y consultas ejecutables con resultados incorrectos. La revisión de casos conserva la categoría automática y su explicación.

Fuente: resultados/validacion_propia.csv, resultados/revision_errores.csv

Verificación de inferencia

Tiempo de carga medido: **6.37 segundos**.

Caso	Determinista	Solo lectura	Máximo (s)
v01	Sí	Sí	5.49
v27	Sí	Sí	8.45
v14	Sí	Sí	7.44

Las mediciones corresponden a la GPU local MX350. No acreditan una ejecución en Colab T4.

Fuente: resultados/contrato_inferencia.json

Predicción de generalización

EX oculta estimada: **0.35**

EX propia observada: 0.439

Se aplica un descuento relativo heurístico del 20% por la generación con plantillas, la validación en solo dos dominios y la selección sobre ese mismo conjunto.

Se procesaron 304 ejemplos del corpus de 3,023 pares. La cobertura limitada y las redacciones repetidas pueden reducir el rendimiento en esquemas y preguntas desconocidos.

Fuente: resultados/analisis.md, resultados/resumen_resultados.json