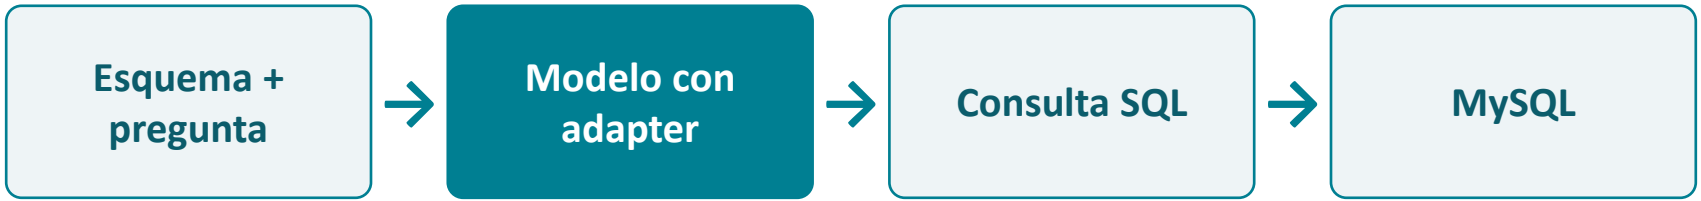
Text-to-SQL con QLoRA

Generación de consultas MySQL a partir de preguntas en español

Nina Nájera y Alejandro Antón

Deep Learning · Universidad del Valle de Guatemala

Objetivo y funcionamiento



Modelo
Qwen2.5-Coder-0.5B-Instruct

Salida
Una sola consulta SELECT o WITH SELECT

Generación
Determinista, sin APIs externas

Límites
300 s de carga y 30 s por pregunta

Datos y separación de esquemas

3,023
pares aceptados

10
dominios de entrenamiento

40
preguntas de validación

Nivel	Entrenamiento	Validación
Fácil	1,086	12
Medio	891	14
Difícil	1,046	14

- Hotel y fútbol se reservaron para validación y no aparecen en entrenamiento.
- 79 descartes: 75 por resultado vacío y 4 por más de 500 filas.
- Validado en MySQL 8.4.10 con ONLY_FULL_GROUP_BY.

Cómo se mide la exactitud

EX = suma de pesos acertados / suma de pesos

- Se comparan los resultados ejecutados de las consultas.
- Pesos 1, 2 y 3 (fácil, medio, difícil); total 82.
- Los números se redondean a dos decimales.
- El orden cuenta solo cuando se solicita; se permiten columnas adicionales.

1.000

EX del oráculo

Comprueba el evaluador; no representa el rendimiento del modelo.

Diseño experimental

	Rango 8	Rango 16
Parámetros entrenables	**540,672**	**1,081,344**
Pasos / ejemplos	756 / 3,023	756 / 3,023
Tiempo en T4	27.1 min	27.0 min

Continuación desde 76 pasos y 304 ejemplos por rango. Se recorrió una época adicional completa en T4.

Se mantiene igual

Base NF4 / FP16

alpha 16 · dropout 0.05

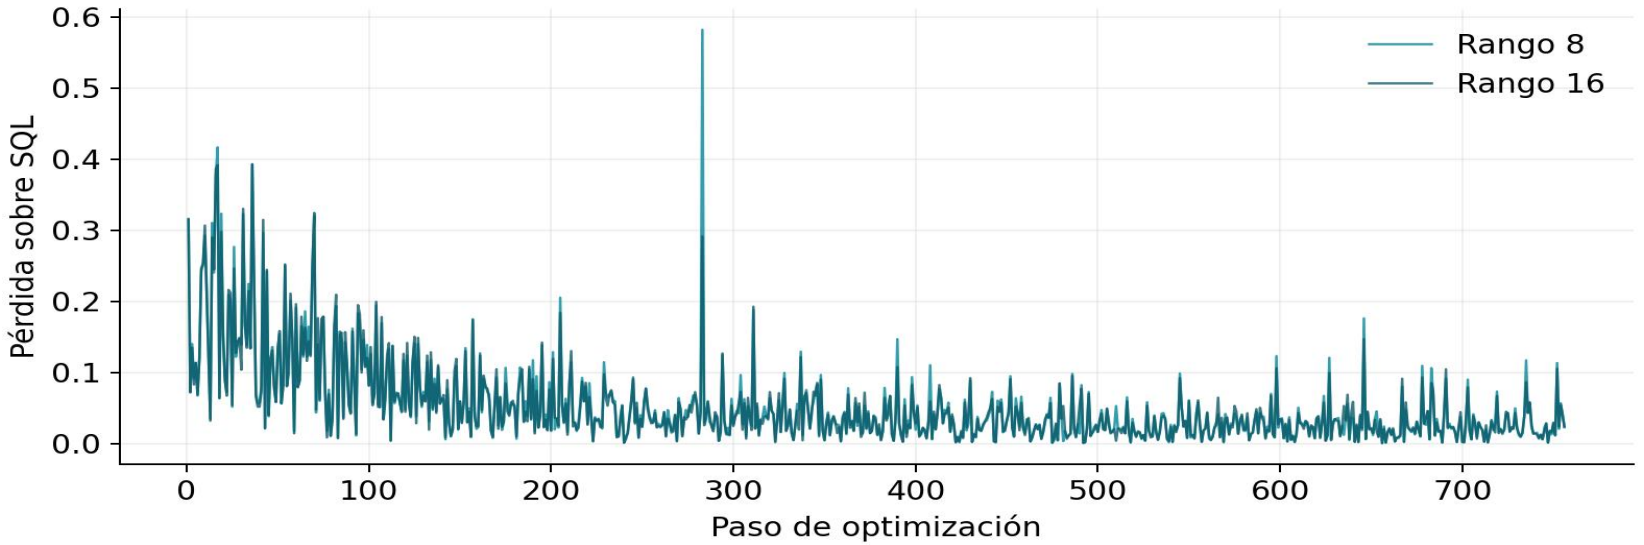
q_proj y v_proj

Tasa 0.0001

Misma semilla y orden

Hipótesis previa: más rango podría representar más relaciones; menos rango podría reducir el sobreajuste.

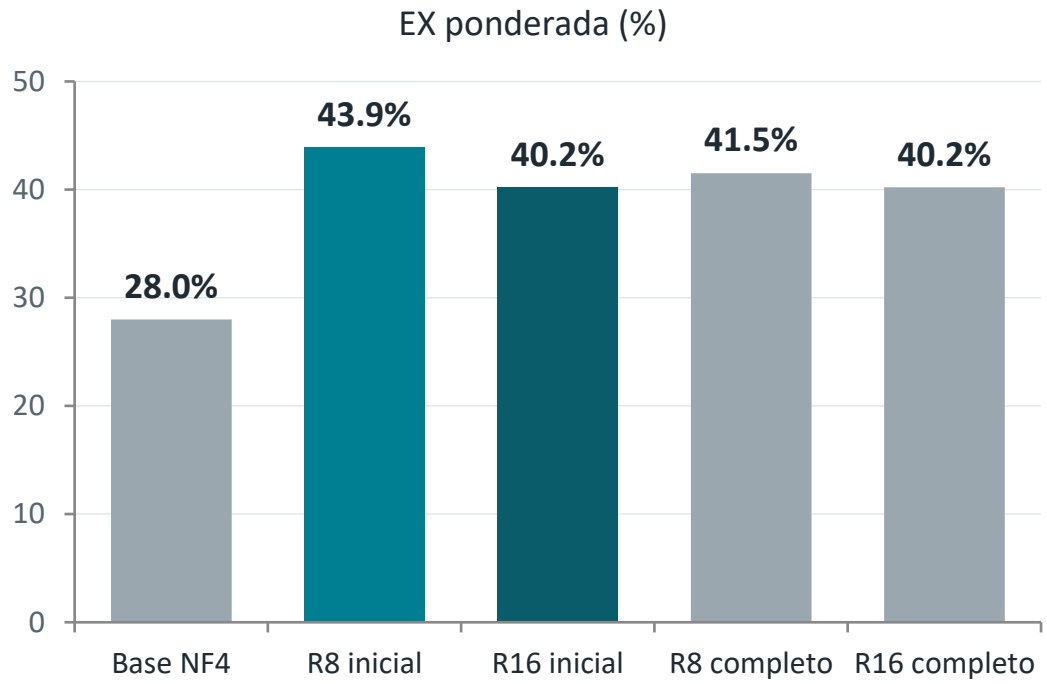
Curvas de entrenamiento



Continuación: una época completa por rango en T4.

Una pérdida menor no garantiza mayor EX en esquemas nuevos.

Resultados principales



+15.9 pp

rango 8 frente al baseline, sin reparación

Seleccionado

R8 + reparación

EX 45.1%

Experimento de reparación

Inferencia	EX	Aciertos	Tiempo medio
Sin reparación	**0.439**	21/40	3.18 s
Con reparación	0.451	22/40	4.93 s

Entrega

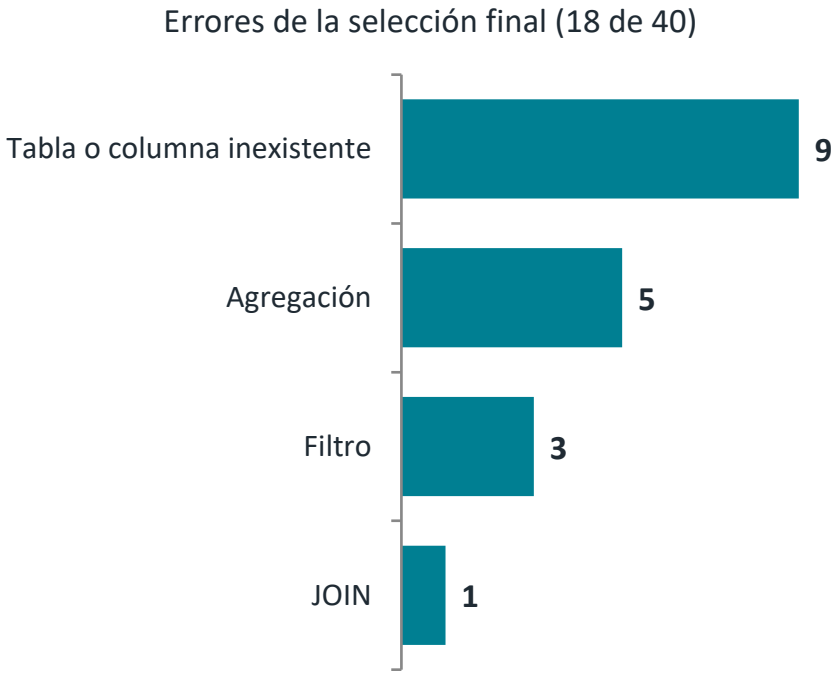
Reparación activada

1 Corrección conservadora de identificadores

2 Regeneración con el error de MySQL

- Hasta dos llamadas de diagnóstico y presupuesto conjunto de 25 s.
- Una consulta ejecutable puede seguir respondiendo mal; la regeneración puede quedar incompleta bajo el límite de tiempo.

Análisis de errores



Columna inexistente (v13)

```
Pred: AVG(h.tarifa_noche)
Ref:  AVG(t.tarifa_noche)
```

La tarifa pertenece a tipos_habitacion.

Agregación (v08)

```
Pred: HAVING COUNT(*) > 15
Ref:  HAVING SUM(r.noches) > 15
```

Se contó en lugar de sumar noches.

Verificación de inferencia

4.89 s
carga del modelo

3 de 3
casos repetidos cumplidos

25
pruebas automatizadas aprobadas

✓ **Determinismo**

✓ **Solo lectura**

✓ **Límite de llamadas**

✓ **Límite de tiempo**

Validación e inferencia comprobadas en Tesla T4. Tiempo máximo por pregunta: 25.15 s.

Conclusiones y predicción

Rango 8
adapter elegido

Con reparación
estrategia elegida

0.451
EX propia final

0.36
EX oculta estimada

La estimación aplica un descuento relativo heurístico del 20%; no es una medición oficial ni un intervalo de confianza.

Límites

Datos basados en plantillas

Solo dos dominios de validación

Mayor cobertura sin mejora de EX